ДОМАШНЯЯ РАБОТА ПО БИОИНФОРМАТИКЕ

Динамика связывания Foxd3 в ходе развития нервного гребня

Сравнительный анализ bioChIP-seq на четырёх стадиях Danio rerio: 75% epiboly → 1–2 ss → 5–6 ss → 14 ss

Объект исследования

Транскрипционный фактор Foxd3 и его геномные участки связывания в процессе формирования нервного гребня.

Исходные данные: Lukoseviciute et al. (2018), GEO GSE106676
Референсный геном: Danio rerio, GRCz11

Содержание

1. Цель работы и исходные данные
2. Биологический и экспериментальный контекст
3. Обработка данных и статистика peak calling
4. Контроль качества и результаты по стадиям
5. Сравнение наборов пиков
6. Технические особенности стадии 14ss
7. Проверка отдельных локусов в IGV
8. Биологическая интерпретация и выводы

Приложение. Основные команды анализа

Краткий итог

Анализ показывает выраженную динамику связывания Foxd3. На ранних стадиях (75ep и 1–2ss) обнаружен небольшой набор пиков; на стадии 5–6ss число детектируемых участков резко возрастает до 839; к стадии 14ss набор снова меняется. Наиболее чистое обогащение ChIP относительно Input наблюдается на 5–6ss.

ГЛАВНЫЙ РЕЗУЛЬТАТ

Переход к стадии 5–6ss сопровождается расширением набора детектируемых участков Foxd3, при этом 61–75% ранних пиков перекрываются с пиками 5–6ss. Интерпретация различий между стадиями требует осторожности: глубина библиотек и качество сигнала неодинаковы, а 31% пиков 14ss находятся на неразмещённых скаффолдах.

В отчёте объединены методические пояснения и результаты двух исходных материалов. Для количественных сравнений использована сводка с обновлёнными расчётами; дополнительные объяснения конвейера и статистики пиков включены в методический раздел.

1. Цель работы и исходные данные

Цель работы — проследить, как меняется геномный ландшафт связывания транскрипционного фактора Foxd3 от гаструляции до миграции нервного гребня Danio rerio. Отдельная задача — оценить, какие различия между стадиями могут отражать биологическую динамику, а какие могут быть связаны с особенностями библиотек ChIP-seq.

Рассматривались четыре стадии развития. Результаты для 75ep и 1–2ss получены в рамках самостоятельной обработки; 14ss анализировалась на семинаре и была пересчитана; для 5–6ss использованы подготовленные файлы преподавателя.

Стадия	Время, hpf	Этап развития	Источник результата
75ep	≈ 8	Поздняя гаструляция, ранние предшественники	Собственный анализ
1–2ss	≈ 10,3–10,7	Индукция нервного гребня	Собственный анализ
5–6ss	≈ 11,7–12	Спецификация нервного гребня	Файлы преподавателя
14ss	≈ 16	Начало миграции нервного гребня	Семинар; повторная обработка

Все исходные BAM-файлы содержат paired-end выравнивания на сборку GRCz11 после исключения митохондриальных ридов. Хромосомы обозначены RefSeq-идентификаторами; записи вида NW_ соответствуют неразмещённым скаффолдам.

1.1 План анализа

- Проверка BAM-файлов и глубины библиотек ChIP и Input.
- Построение CPM-покрытия, дорожки $\log_2$(ChIP/Input) и вызов пиков MACS3.
- Расчёт FRiP, построение heatmap и средних профилей вокруг summit.
- Сравнение числа пиков, их попарного перекрытия, индекса Жаккара и стадийно-специфичных участков.
- Проверка характерных локусов в IGV.

2. Биологический и экспериментальный контекст

2.1 Foxd3 и нервный гребень

Foxd3 — транскрипционный фактор семейства forkhead, участвующий в формировании нервного гребня. В работе Lukoseviciute et al. (2018) обсуждается изменение его роли в ходе развития: на ранних этапах Foxd3 может действовать как pioneer-фактор, подготавливая регуляторные элементы, а позднее участвовать в подавлении некоторых программ дифференцировки. Для обоснования функциональной роли авторы объединяли bioChIP-seq с ATAC-seq, ChIP-seq по H3K27ac и RNA-seq.

ОГРАНИЧЕНИЕ CHIP-SEQ

ChIP-seq показывает участки генома, с которыми ассоциирован исследуемый белок. Сам по себе этот метод не позволяет заключить, активирует Foxd3 соседний ген или подавляет его.

2.2 Принцип bioChIP-seq

В эксперименте Foxd3 снабжён AviTag и биотинилируется in vivo биотин-лигазой BirA. После сшивки белков с ДНК хроматин фрагментируют, а фрагменты, связанные с биотинилированным Foxd3, обогащают с помощью стрептавидина и секвенируют. Полученные прочтения выравнивают на геном GRCz11.

В качестве контрольного образца используется Input — хроматин до стадии обогащения. Он отражает фон, связанный с фрагментацией, картируемостью, GC-составом и особенностями секвенирования. Отдельный контроль BirA-only позволяет оценить неспецифическое связывание со стрептавидином, но в рассматриваемом peak calling использовался Input.

2.3 От прочтений к пикам

В paired-end библиотеке два прочтения соответствуют концам одного фрагмента ДНК. bamCoverage без --extendReads считает покрытие по самим прочтениям, тогда как MACS3 в режиме BAMPE восстанавливает фрагмент целиком по паре. Поэтому BigWig-дорожка покрытия и оценка фрагментов MACS3 описывают близкие, но не полностью одинаковые величины.

Пик — это геномный интервал, где обогащение ChIP относительно локального фона проходит установленный статистический порог. Summit — позиция максимального сигнала внутри такого интервала. Пик не обязательно соответствует одному сайту связывания: близкие события могут объединяться, а слабые сайты могут не пройти порог значимости.

3. Обработка данных и статистика peak calling

3.1 Основные форматы

Формат	Что содержит	Использование в анализе
BAM / BAI	Выровненные прочтения и индекс координатного доступа	QC, покрытие, MACS3, FRiP, IGV
BigWig	Непрерывный сигнал по геному (например, CPM)	Сравнение ChIP и Input, профили, IGV
BED	Геномные интервалы или отдельные координаты	Summits, пересечения, интервалы генов
narrowPeak	Пики MACS3 и статистические показатели	Число пиков, значимость, сравнение стадий
matrix.gz	Матрица «пики × бины» в окне вокруг summit	Heatmap и средний профиль deepTools
GTF	Аннотация генов и транскриптов	Связь пиков с генами и TSS в IGV

3.2 Этапы конвейера

Для доступных BAM-файлов 75ep, 1–2ss и 14ss использовалась одинаковая последовательность действий. Для 5–6ss анализировались готовые результаты преподавателя.

- Контроль BAM: samtools flagstat показывает доли выровненных прочтений, правильных пар и записи с соответствующими флагами.
- Нормировка покрытия: bamCoverage делит геном на бины по 10 п.н. и рассчитывает покрытие на миллион выровненных прочтений (CPM).
- Отношение ChIP/Input: bigwigCompare строит $\log_2$-дорожку, позволяющую визуально находить области обогащения.
- Вызов пиков: MACS3 сравнивает ChIP с Input, используя целые paired-end фрагменты в режиме BAMPE.
- FRiP и профили: рассчитывается доля выравниваний в пределах пиков; computeMatrix, plotHeatmap и plotProfile описывают сигнал вокруг summit.

3.3 Нормировка сигнала

CPM-нормировка устраняет простые различия в количестве прочтений между библиотеками, но не делает образцы полностью сопоставимыми: могут сохраняться различия в эффективности иммунопреципитации, составе клеток, длинах фрагментов и уровне фонового сигнала.

ФОРМУЛА ДОРОЖКИ ОБОГАЩЕНИЯ

Для каждого бина x рассчитывается $S(x) = \log_2[(ChIP(x) + 1) / (Input(x) + 1)]$. Положительное значение означает, что сигнал ChIP выше Input. Псевдосчёт 1 предотвращает деление на ноль, но при малых CPM сжимает отношение, поэтому дорожку не следует использовать как точную оценку fold-enrichment.

3.4 Как MACS3 определяет значимые пики

MACS3 оценивает наблюдаемое количество ChIP-фрагментов k в каждой позиции и сравнивает его с ожидаемым локальным фоном λlocal, который рассчитывается по Input в окнах нескольких размеров. Для консервативной оценки используется наибольшая из локальных фоновых оценок. При нулевой гипотезе число фоновых фрагментов моделируется распределением Пуассона:

$$K \sim \text{Poisson}(\lambda local), \quad p = P(K \geq k \mid \lambda local)$$

p-value — вероятность получить k или больше фрагментов при условии, что наблюдаемый сигнал объясняется только фоном. Поскольку по геному выполняется огромное число проверок, p-value корректируется методом Бенджамини–Хохберга. q-value отражает уровень FDR, при котором пик остаётся значимым. В работе использован порог q ≤ 0,01.

Параметры peak calling

Параметр	Значение / назначение
-t / -c	ChIP (treatment) и контроль Input
-f BAMPE	Использование целых фрагментов, восстановленных по paired-end парам
-g 1360000000	Эффективный размер генома
-q 0.01	Порог q-value для отбора пиков
--scale-to small	Приведение более глубокой библиотеки к размеру меньшей (поведение по умолчанию)

3.5 Как читать narrowPeak

Поле	Содержание
1–3: chrom, start, end	Хромосома и границы пика; координаты 0-based, интервал полуоткрытый [start, end).
4–6: name, score, strand	Имя пика, оценка для браузера и цепь (для TF обычно не определяется).
7: signalValue	Fold-enrichment в вершине пика относительно локального фона.
8: pValue	$-\log_{10}$(p-value).
9: qValue	$-\log_{10}$(q-value); фактический q = 10^(−значение в колонке 9).
10: peak	Смещение summit относительно начала интервала.

Большое значение $-\log_{10}(q)$ означает высокую статистическую значимость, но не обязательно более сильное связывание. На q-value влияет глубина библиотеки; для оценки интенсивности полезно дополнительно рассматривать signalValue и количественный сигнал ChIP/Input.

3.6 FRiP и профили

FRiP (fraction of reads in peaks) рассчитывался как число выравниваний ChIP, попавших в интервалы narrowPeak, делённое на общее число выравниваний ChIP. В данной работе использован подсчёт по записям BAM (прочтениям), поэтому для paired-end данных это не тождественно подсчёту по целым фрагментам.

Для heatmap и среднего профиля вокруг summit брали окно ±2 kb с размером бина 20 bp. Матрица содержит по одной строке на пик; heatmap показывает разброс сигнала по отдельным пикам, а средний профиль — усреднённую форму сигнала.

4. Контроль качества и результаты по стадиям

4.1 Глубина библиотек

Стадия	ChIP, выравн.	ChIP, фрагм.	Input, выравн.	Input / ChIP	QC BAM
75ep	23 863 894	11 931 947	39 931 858	1,67	100% mapped / paired
1–2ss	12 816 614	6 408 307	33 460 348	2,61	100% mapped / paired
5–6ss	18 853 396	9 426 698	≈57 051 062*	3,03	Нет данных
14ss	41 553 880	20 776 940	27 794 668	0,67	100% mapped / paired

* Для 5–6ss исходный BAM в материалах отсутствует; число выравниваний Input оценено как удвоенное число фрагментов из заголовка peaks.xls. Показатели flagstat для этой стадии проверить нельзя.

Доступные BAM-файлы 75ep, 1–2ss и 14ss содержат уже отфильтрованные парные выравнивания: в них указано 100% mapped и properly paired. Отсутствие записей, помеченных как дубликаты, само по себе не доказывает, что дубликаты были предварительно удалены или корректно размечены.

4.2 Сводные показатели

Стадия	Пики	FRiP, %	max −log₁₀(q)	Медиана FE	ChIP/Input в summit
75ep	36	0,017	100,05	5,64	2,1
1–2ss	40	0,014	56,18	6,00	7,0
5–6ss	839	0,236	163,70	5,52	8,3
14ss	170	0,162	321,45	3,29	1,7

Число выравниваний внутри пиков для расчёта FRiP: 4 101 (75ep), 1 799 (1–2ss), 44 485 (5–6ss) и 67 346 (14ss). Для 5–6ss показатель приведён в готовых материалах преподавателя.

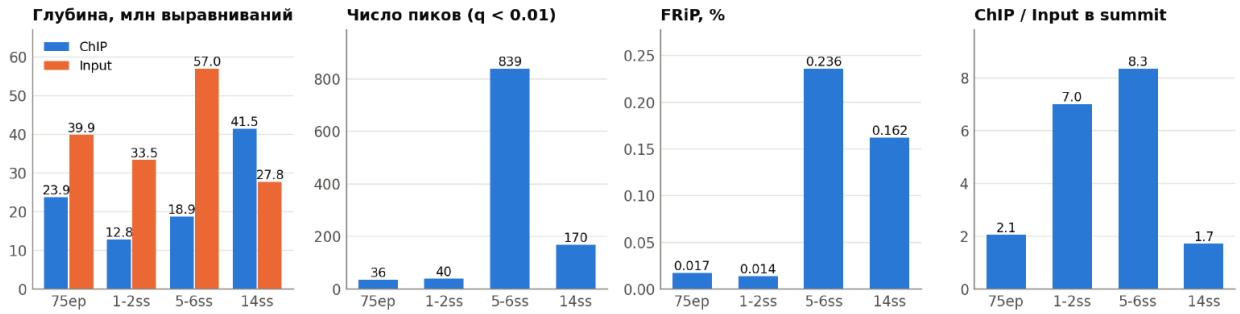


Рис. 1. Глубина библиотек, число пиков, FRiP и отношение ChIP/Input в summit. У панелей собственные шкалы.

На 5–6ss обнаружено больше всего пиков (839), хотя глубина ChIP этой стадии ниже, чем на 75ep и 14ss. Кроме того, для 5–6ss характерны максимальные FRiP (0,236%) и отношение ChIP/Input в summit (8,3). Это согласуется с более выраженным обогащением, хотя полностью отделить биологический эффект от технических различий нельзя.

Стадия 14ss имеет самую глубокую ChIP-библиотеку и максимальную статистическую значимость отдельных пиков, однако медианное fold-enrichment и отношение ChIP/Input здесь минимальны. Следовательно, q-value нельзя трактовать как прямую меру силы связывания.

4.3 Heatmap и средние профили вокруг summit

Heatmap позволяет оценить, насколько однороден сигнал среди всех пиков стадии. На 75ep центральное обогащение ChIP заметно в большинстве строк, однако у части верхних строк повышен и Input — вероятен вклад фоновых областей. На 1–2ss абсолютное покрытие ChIP ниже, что согласуется с меньшей глубиной библиотеки, но центральный сигнал лучше отделён от Input.

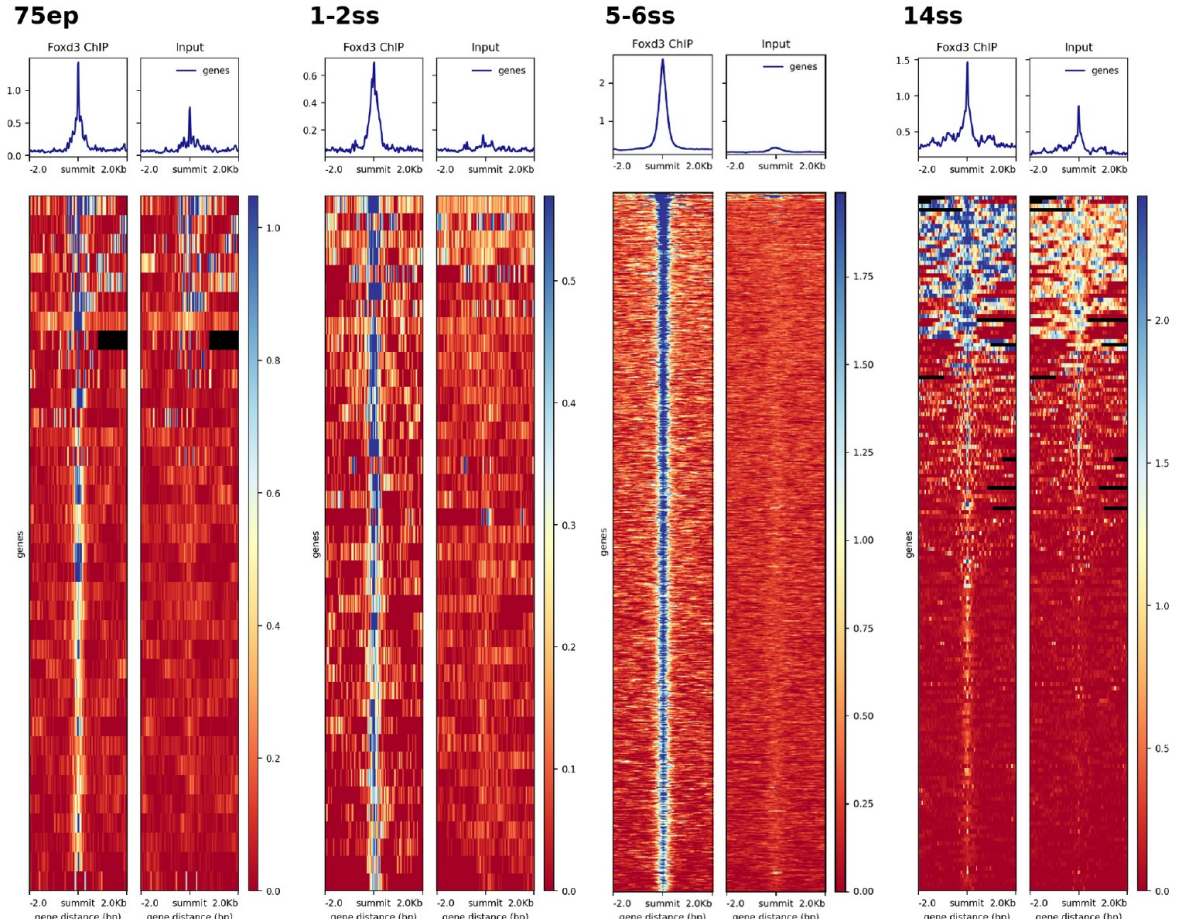


Рис. 2. Heatmap и средние профили ChIP CPM и Input CPM вокруг summit для четырёх стадий (окно ±2 kb). Цветовые шкалы различаются между стадиями; чёрные участки соответствуют отсутствующим значениям на краях коротких скаффолдов.

На 5–6ss наблюдается наиболее однородная картина: узкая центральная полоса ChIP прослеживается по большинству из 839 пиков, а Input остаётся относительно ровным. На 14ss верхняя часть heatmap содержит строки с повышенным сигналом и в ChIP, и в Input; значительная доля таких участков расположена на неразмещённых скаффолдах NW_.

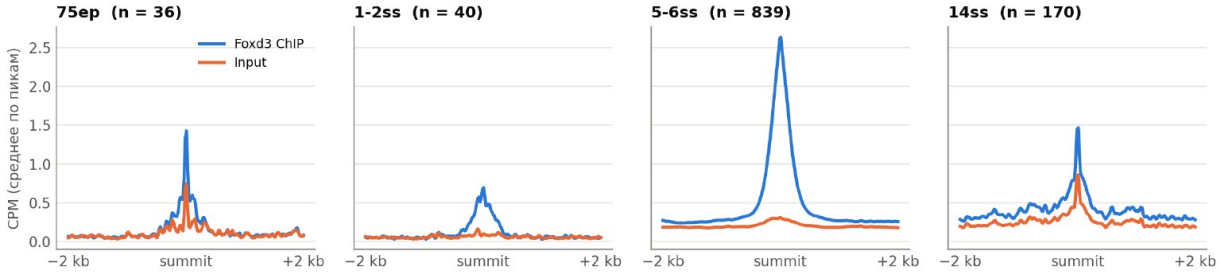


Рис. 3. Средние профили ChIP и Input с общей шкалой CPM. Общая ось Y позволяет сопоставлять высоту сигнала между стадиями.

Отношение ChIP/Input в центре среднего профиля составляет: 2,1 для 75ep; 7,0 для 1–2ss; 8,3 для 5–6ss; 1,7 для 14ss. У 75ep и 14ss центральное значение Input заметно повышено, поэтому часть видимого ChIP-сигнала может быть связана с локальным фоном. Подписи «genes» и «gene distance» на исходной heatmap являются стандартными подписями deepTools: строки здесь соответствуют пикам, а горизонтальная ось — расстоянию до summit.

5. Сравнение наборов пиков

5.1 Попарное перекрытие

Для каждой пары стадий bedtools intersect использовался, чтобы посчитать, сколько интервалов одной стадии пересекаются хотя бы на 1 bp с интервалами другой. Эта доля направленная: при перестановке стадий A и B результат может измениться. Индекс Жаккара рассчитывался по нуклеотидам после объединения перекрывающихся интервалов: J = |A ∩ B| / |A ∪ B|.

Пара стадий	Пики A / B	A ∩ B (доля A)	B ∩ A (доля B)	Только A / B	Jaccard
75ep / 1–2ss	36 / 40	12 (33%)	12 (30%)	24 / 28	0,174
75ep / 5–6ss	36 / 839	22 (61%)	22 (2,6%)	14 / 817	0,023
75ep / 14ss	36 / 170	18 (50%)	18 (11%)	18 / 152	0,075
1–2ss / 5–6ss	40 / 839	30 (75%)	30 (3,6%)	10 / 809	0,028
1–2ss / 14ss	40 / 170	12 (30%)	12 (7,1%)	28 / 158	0,043
5–6ss / 14ss	839 / 170	40 (4,8%)	40 (24%)	799 / 130	0,037

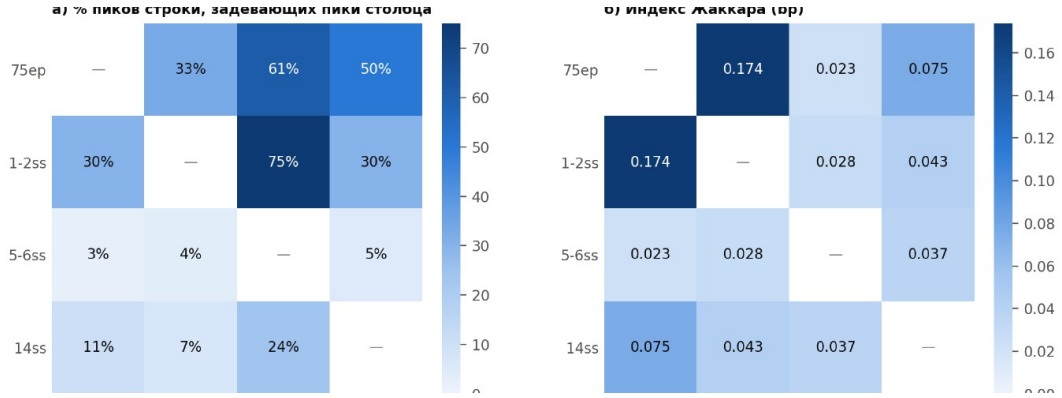


Рис. 4. Направленные доли перекрытия и индекс Жаккара для всех четырёх стадий.

Наиболее похожи по индексу Жаккара стадии 75ep и 1–2ss (0,174). При этом ранние наборы в значительной степени входят в набор 5–6ss: с ним пересекаются 61% пиков 75ep и 75% пиков 1–2ss. Низкий Жаккар этих пар объясняется прежде всего большой разницей в числе пиков.

Наиболее выраженное различие наблюдается между 5–6ss и 14ss: с пиками 14ss пересекаются только 40 из 839 пиков 5–6ss (4,8%). В обратном направлении с набором 5–6ss пересекаются 40 из 170 пиков 14ss (24%). Это указывает на заметную перестройку репертуара детектируемых участков к стадии миграции.

5.2 Общие и стадийно-специфичные пики

Стадия	Всего пиков	Специфичны для стадии	Есть хотя бы на другой стадии
75ep	36	6 (17%)	30
1–2ss	40	7 (18%)	33
5–6ss	839	773 (92%)	66
14ss	170	119 (70%)	51

Стадийно-специфичным считался пик, не перекрывающийся ни с одним пиком трёх остальных стадий. На всех четырёх стадиях обнаружены шесть общих локусов: chr6:32,206 Mb; chr2:33,276 Mb; chr16:7,515 Mb; chr20:9,428 Mb; chr18:44,276 Mb и chr4:24,986 Mb.

ВАЖНОЕ РАЗЛИЧИЕ

«Не перекрывается с пиками одной другой стадии» не означает «уникален среди всех стадий». В таблице выше приведены результаты сравнения со всеми тремя остальными наборами; парные числа «только A / только B» относятся лишь к конкретной паре.

6. Технические особенности стадии 14ss

6.1 Пики на неразмещённых скаффолдах

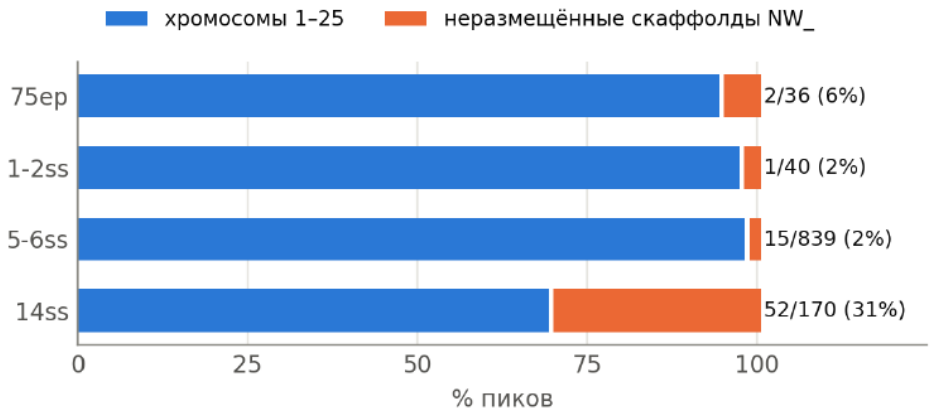


Рис. 5. Доля пиков на хромосомах 1–25 и неразмещённых скаффолдах NW_.

На стадии 14ss 52 из 170 пиков (31%) расположены на неразмещённых скаффолдах NW_; 20 из них приходятся на NW_003336678.1. Для остальных стадий доля таких пиков составляет около 1–6%. У этих участков сравнительно низкий fold-enrichment (около 3), но высокая статистическая значимость; в Input также наблюдается повышенный сигнал: средний CPM в центре составляет 1,55 против 0,39 у пиков на хромосомах 1–25.

Подобная картина может быть связана с повторами и проблемными участками сборки: риды способны картироваться в нескольких местах, повышая покрытие и в ChIP, и в Input. При большой глубине библиотеки даже небольшое различие между ними может давать очень низкий q-value. Поэтому такие пики следует считать потенциально техническими и исключить или отдельно проверить перед биологической интерпретацией — например, с помощью blacklist или фильтра по размещённым хромосомам.

ПОСЛЕДСТВИЕ ДЛЯ СРАВНЕНИЯ СТАДИЙ

Часть «новых» пиков 14ss может быть следствием картирования на скаффолды, а не появления новых биологических мишеней Foxd3. Это уменьшает уверенность в буквальной интерпретации 70% стадийно-специфичных пиков этой стадии.

6.2 Почему отсутствие пика не доказывает отсутствие связывания

Пик определяется бинарно по установленному порогу. Сайт может быть связан с Foxd3, но не пройти q ≤ 0,01 из-за низкой глубины библиотеки, присутствия сигнала лишь в небольшой клеточной популяции или небольшого смещения координат, из-за которого интервалы формально не пересекаются. Поэтому наборы пиков полезно дополнять сравнением количественного сигнала в одних и тех же локусах на всех стадиях.

7. Проверка отдельных локусов в IGV

В IGV сопоставлялись BigWig-дорожки ChIP CPM и Input CPM, $\log_2$(ChIP/Input), narrowPeak для четырёх стадий, а также последовательность и аннотация RefSeq. Шкалы отдельных $\log_2$-дорожек в исходных скриншотах автоматические и различаются, поэтому для количественного сравнения использовались значения, приведённые в подписях к локусам.

7.1 Сильный пик 5–6ss: chr3

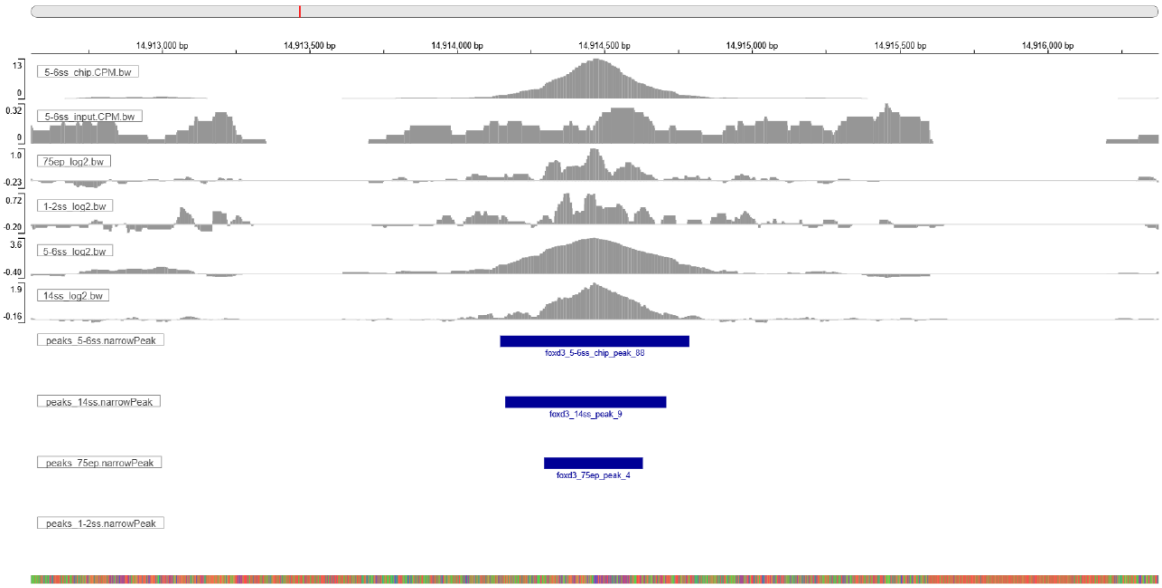


Рис. 6. IGV-окно chr3:14 912 700–14 916 300; пик foxd3_5-6ss_chip_peak_88.

Пик chr3:14 914 145–14 914 787 имеет самый высокий fold-enrichment среди рассмотренных пиков 5–6ss: signalValue = 31,0 и $-\log_{10}(q)$ = 135,7. Внутри пика расположен интрон гена NM_001040248.1. На 5–6ss ChIP достигает примерно 12,5 CPM, тогда как Input остаётся около 0,3 CPM. Сигнал также детектируется на 75ep и 14ss; на 1–2ss он заметен, но не проходит порог вызова пика. Это пример того, как отсутствие вызванного пика может отражать недостаточную статистическую мощность, а не отсутствие связывания.

7.2 Локус, общий для четырёх стадий: chr2

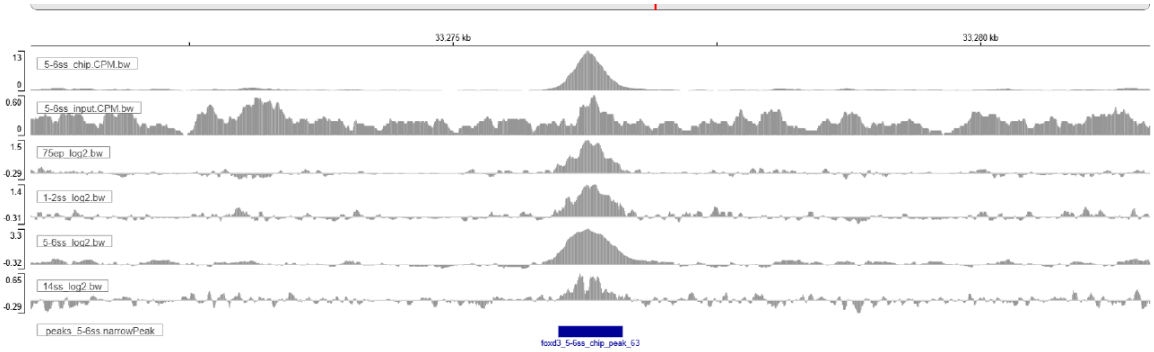


Рис. 7. IGV-окно chr2:33 270 999–33 281 609; общий локус около chr2:33,276 Mb.

Пик около chr2:33 276 000 вызван на всех четырёх стадиях. Максимум $\log_2$(ChIP/Input) составляет 1,54 (75ep), 1,44 (1–2ss), 3,27 (5–6ss) и 0,67 (14ss); fold-enrichment — около 21,7 / 21,2 / 20,3 / 5,5 соответственно. В окне ±5 kb нет генов RefSeq, поэтому участок может быть дистальным регуляторным элементом. Пример показывает, что наличие пика на всех стадиях не означает одинаковую интенсивность связывания.

7.3 Локус со смещением к стадии 5–6ss: chr1

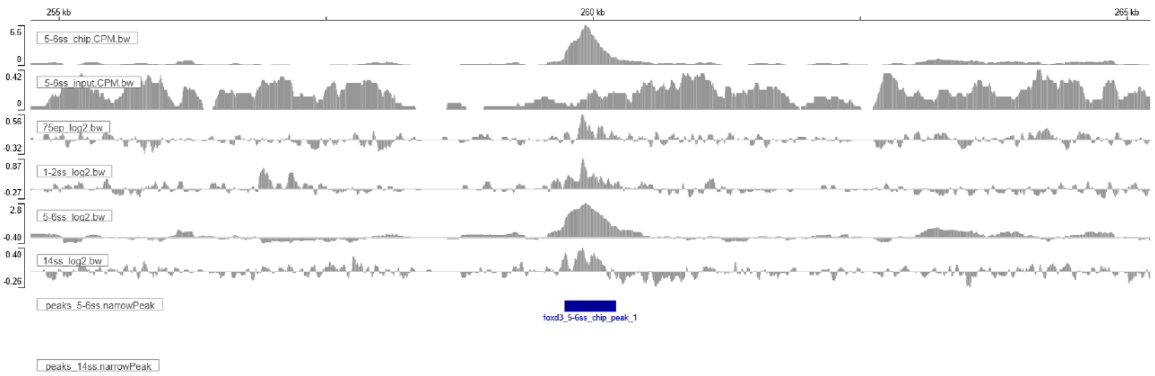


Рис. 8. IGV-окно chr1:254 734–265 218; пик foxd3_5-6ss_chip_peak_1.

Пик chr1:259 734–260 218 вызван только на 5–6ss (signalValue = 21,0; $-\log_{10}(q) = 63{,}0$) и перекрывает 5′-конец транскрипта NM_001327759.1, то есть, вероятно, расположен в промоторной области. Максимум $\log_2$(ChIP/Input) равен 0,56 (75ep), 0,87 (1–2ss), 2,78 (5–6ss) и 0,40 (14ss). Корректнее называть этот участок stage-biased — со смещением к 5–6ss, а не строго stage-specific: слабый сигнал на остальных стадиях остаётся возможным.

8. Биологическая интерпретация

Совокупность результатов указывает на двухэтапное изменение набора детектируемых участков Foxd3. На стадиях 75ep и 1–2ss выявляется небольшое ядро пиков. На стадии спецификации 5–6ss оно расширяется до сотен участков, причём большая часть ранних пиков сохраняется: с набором 5–6ss пересекаются 61% пиков 75ep и 75% пиков 1–2ss. К 14ss большая часть пиков 5–6ss уже не детектируется, а набор 14ss выглядит существенно иначе.

Максимум детектируемого связывания приходится на 5–6ss: на этой стадии больше всего пиков, максимальны FRiP и отношение ChIP/Input в summit, а heatmap демонстрирует наиболее однородное центральное обогащение. Такая картина согласуется с расширением программы регуляции Foxd3 во время спецификации нервного гребня.

Наблюдаемая динамика в целом совместима с моделью Lukoseviciute et al. (2018): на ранних этапах Foxd3 может подготавливать регуляторные участки, а позднее участвовать в изменении программ дифференцировки. Однако по одному ChIP-seq нельзя установить, какие гены регулируются напрямую и в каком направлении.

КАКИЕ ДАННЫЕ НУЖНЫ ДЛЯ ФУНКЦИОНАЛЬНОГО ВЫВОДА

ATAC-seq поможет проверить изменение доступности хроматина; H3K27ac ChIP-seq — активность регуляторных элементов; RNA-seq — изменение экспрессии потенциальных генов-мишеней. Согласованное изменение этих показателей после потери Foxd3 позволит лучше обосновать прямой регуляторный эффект.

9. Ограничения анализа и выводы

9.1 Ограничения

- Глубина ChIP-библиотек различается: на 1–2ss число выравниваний примерно в 3,2 раза меньше, чем на 14ss. Слабые сайты могут не достигать порога значимости.
- Материалы 5–6ss получены отдельно; исходный BAM недоступен, поэтому невозможно самостоятельно проверить все этапы QC и полное совпадение параметров обработки.
- На 14ss 31% пиков расположены на неразмещённых скаффолдах NW_; часть из них, вероятно, отражает особенности картирования.
- ChIP выполнялся на целых эмбрионах. Сигнал из небольшой популяции Foxd3-положительных клеток может разбавляться остальными клетками.
- Биологические повторы отсутствуют, поэтому воспроизводимость различий оценить нельзя.
- FRiP рассчитан по выравниваниям и зависит не только от концентрации сигнала, но и от общего размера и ширины набора пиков.
- Перекрытие интервалов на 1 bp — мягкий критерий; для строгого вывода следует проверить устойчивость результата при более высоком пороге доли перекрытия и подходящем фоновом тесте.

9.2 Что улучшить в дальнейшем

- Повторить анализ всех стадий с едиными параметрами и доступом к исходным BAM, включая 5–6ss.
- Выполнить downsampling библиотек, чтобы оценить влияние глубины на число обнаруживаемых пиков.
- Построить единый consensus-набор локусов и сравнить количественный сигнал ChIP/Input на одинаковых регионах.
- Исключить blacklist и проблемные неразмещённые скаффолды, отдельно проверить повторы и картируемость.
- Добавить биологические повторы и, для функциональной интерпретации, интегрировать ChIP-seq с ATAC-seq, H3K27ac и RNA-seq.

9.3 Вывод

От гаструляции и индукции нервного гребня к стадии спецификации число детектируемых пиков Foxd3 резко увеличивается (36–40 → 839), при этом большая часть ранних участков сохраняется. На стадии миграции набор пиков снова меняется: большинство пиков 5–6ss не обнаруживается на 14ss, а часть пиков 14ss может быть связана с картированием на неразмещённые скаффолды. Наиболее выраженное и чистое обогащение ChIP относительно Input наблюдается на 5–6ss.

Таким образом, данные поддерживают гипотезу о динамической перестройке связывания Foxd3 в ходе развития нервного гребня. При этом точные масштабы появления и исчезновения сайтов, а также функциональное направление регуляции требуют подтверждения с помощью унифицированной обработки, биологических повторов и дополнительных эпигеномных и транскриптомных данных.

Источник данных

Lukoseviciute et al. (2018), Developmental Cell. Набор данных bioChIP-seq: GEO GSE106676. Референсная сборка генома: Danio rerio GRCz11.

Приложение. Основные команды анализа

Ниже приведён сокращённый вариант последовательности команд для доступных стадий 75ep, 1–2ss и 14ss. Для стадии 5–6ss использовались готовые результаты преподавателя; запускать этот цикл для неё можно только при наличии соответствующих BAM-файлов.

```
# Проверка BAM
samtools flagstat "$CHIP" > chip.flagstat.txt
samtools flagstat "$INPUT" > input.flagstat.txt

# CPM-покрытие
bamCoverage -b "$CHIP" -o chip.CPM.bw \
  --normalizeUsing CPM --binSize 10 -p 4
bamCoverage -b "$INPUT" -o input.CPM.bw \
  --normalizeUsing CPM --binSize 10 -p 4

# log2(ChIP / Input)
bigwigCompare -b1 chip.CPM.bw -b2 input.CPM.bw \
  --operation log2 --pseudocount 1 --binSize 10 \
  -o log2_IP_Input.bw

# Вызов пиков
macs3 callpeak -t "$CHIP" -c "$INPUT" -f BAMPE \
  -g 1360000000 -n foxd3_STAGE -q 0.01 --outdir peaks/

# Количество пиков и FRiP
wc -l peaks/foxd3_STAGE_peaks.narrowPeak
TOTAL=$(samtools view -c "$CHIP")
INPEAKS=$(samtools view -c -L peaks/foxd3_STAGE_peaks.narrowPeak "$CHIP")
awk -v a="$INPEAKS" -v b="$TOTAL" 'BEGIN{print a/b}'
```

Построение профилей

```
computeMatrix reference-point --referencePoint center \
  -R peaks/foxd3_STAGE_summits.bed \
  -S chip.CPM.bw input.CPM.bw \
  -b 2000 -a 2000 --binSize 20 \
  -o figures/foxd3_STAGE.matrix.gz

plotHeatmap -m figures/foxd3_STAGE.matrix.gz \
  -out figures/foxd3_STAGE.heatmap.pdf \
  --samplesLabel "Foxd3 ChIP" "Input" \
  --refPointLabel summit --regionsLabel peaks \
  --xAxisLabel "distance to summit (bp)"

plotProfile -m figures/foxd3_STAGE.matrix.gz \
  -out figures/foxd3_STAGE.profile.pdf \
  --samplesLabel "Foxd3 ChIP" "Input" \
  --refPointLabel summit --regionsLabel peaks
```

Сравнение наборов пиков

```
# A и B предварительно сортируются по хромосоме и координате
sort -k1,1 -k2,2n A.narrowPeak > A.sorted.bed
sort -k1,1 -k2,2n B.narrowPeak > B.sorted.bed

# Пики A, пересекающие B, и пики A без пересечения
bedtools intersect -a A.sorted.bed -b B.sorted.bed -u | wc -l
bedtools intersect -a A.sorted.bed -b B.sorted.bed -v | wc -l

# Индекс Жаккара по объединённым интервалам
cut -f1-3 A.sorted.bed | bedtools merge > A.merged.bed
cut -f1-3 B.sorted.bed | bedtools merge > B.merged.bed
bedtools jaccard -a A.merged.bed -b B.merged.bed
```

Команды приведены для иллюстрации логики анализа; перед запуском необходимо подставить корректные пути к BAM и файлам narrowPeak, а также проверить, что входные файлы принадлежат одной сборке генома и используют согласованную систему названий хромосом.