

Влияние загрязнения почвы керосином на состав бактериального сообщества

Ампликонное секвенирование участка V4 гена 16S rRNA, анализ в QIIME 2 2024.10

Объект	дерново-подзолистая почва, закрытые ёмкости, инкубация 360 дней
Варианты загрязнения	k0 — контроль; k5 — 5 г керосина/кг почвы; k25 — 25 г/кг; по 3 реплики на точку
Точки отбора	t1 (день 3), t2 (день 90), t3 (день 180), t4 (день 360) — 36 образцов
Маркер	16S rRNA, праймеры 515F / 907R (участки V4-V5), Illumina MiSeq, 2×250 п.н.
Источник данных	SRA, проект PRJNA786393
Инструменты	FastQC, QIIME 2 2024.10 (контейнер Singularity), DADA2, GreenGenes2 (классификатор на V4)

По условию задания использованы только прямые прочтения (R1): при длине ампликона около 400 п.н. и низком качестве концов обратных прочтений склейка пары в QIIME 2 приводила бы к большой потере данных, поэтому пайплайн построен на одноконцевом анализе R1.

Задача 1. Контроль качества прочтений (FastQC)

Для детального разбора выбран образец **SRR17307316** (k0, повтор 1, 3-и сутки) — один из 36 файлов прямых прочтений в папке raw_reads. Базовые показатели:

Показатель	Значение
Число прочтений	10 833
Длина прочтения	251 п.н.
GC-состав	57 %
Прочтений плохого качества	0

По остальным 35 образцам число прочтений сильно различается — от 5 128 (SRR17307380) до 45 492 (SRR17307475), в сумме 641 362 прочтения, в среднем около 17,8 тыс. на образец. Длина (251 п.н.) и GC-состав (56–57 %) одинаковы у всех файлов, то есть различается только глубина секвенирования, а не качество библиотек.




Рис. 1. Качество по позициям прочтения, SRR17307316 (FastQC, Per base sequence quality)

Медианное качество держится в зелёной зоне ($Q > 34$) практически по всей длине прочтения и начинает заметно проседать только в последних ~15–20 позициях, где разброс (усы) заходит в жёлтую и местами красную зону. Это прямо обосновывает параметр `--p-trunc-len 200` в DADA2 — обрезку именно того участка, где падает качество.




Рис. 2. Состав нуклеотидов по позициям, SRR17307316 (FastQC, Per base sequence content) — помечен FastQC как FAIL

Первые 19 позиций ведут себя не как случайная последовательность: доли A/C/G/T резко скачут от позиции к позиции. Это не дефект данных, а след праймера 515F (GTGCCAGCMGCCGCGGTAA), который идентичен во всех прочтениях и поэтому даёт неслучайный, «пилообразный» рисунок. То же самое подтверждает список overrepresented sequences: самые частые «переобогащённые» последовательности (до ~2,8 % каждая) начинаются именно с GTGCCAGC... / GTGTCAGC... — двух вариантов праймера, различающихся по вырожденной позиции M (A или C). По той же причине FastQC помечает как FAIL разделы Per base sequence content и Sequence Duplication Levels — оба отклонения типичны для ампликонных библиотек, где все прочтения — копии одного короткого участка гена, и не говорят о плохом качестве данных.

Вывод по задаче 1. Данные качественные: ошибок секвенирования мало, адаптеров не обнаружено, качество падает предсказуемо только к самому концу прочтения. Единственная «проблема» — присутствие праймера в начале каждого ряда, что устраняется обрезкой на следующем шаге, и сильная неравномерность глубины между образцами, которую необходимо будет учесть при выборе порога прореживания для метрик разнообразия.

Задача 2. Назначение параметра --p-trim-left 25

Вопрос из задания: зачем мы используем параметр --p-trim-left 25?

Каждое прочтение R1 начинается с 19-нуклеотидной последовательности праймера 515F. Это не биологическая ДНК бактерии, а синтетический олигонуклеотид, добавленный в пробирку при постановке ПЦР, и он одинаков для всех образцов и всех видов бактерий в выборке. Оставлять его в анализе нельзя по трём причинам:

1. **Отсутствие информации.** Раз последовательность одинакова у всех прочтений, она не может использоваться, чтобы отличить одну бактерию от другой — только зашумляет сравнение.
2. **Вырожденность праймера.** В позиции M праймера стоит либо A, либо C (разные молекулы праймера в смеси отличаются). Если не вырезать эту позицию, DADA2 рискует посчитать два варианта одного и того же ампликона, отличающихся только буквой

праймера, за два разных ASV, искусственно завышая оценку разнообразия.

3. **Качество первых циклов секвенирования.** У Illumina первые позиции прочтения в среднем менее точно откалиброваны, чем середина рида.

Значение 25, а не ровно 19, взято с запасом в 6 нуклеотидов: даже если в конкретном прочтении праймер слегка сдвинут или частично перекрывается с соседним консервативным участком, такой отступ гарантирует, что праймер срезается целиком. После обрезки справа (--p-trunc-len 200) и слева (--p-trim-left 25) каждый итоговый вариант ампликона (ASV) имеет одинаковую длину $200 - 25 = 175$ п.н. — это важно, поскольку DADA2 сравнивает последовательности позиционно и разная длина одного и того же фрагмента была бы воспринята как разные ASV.

Задача 3. Статистика фильтрации DADA2

Вопрос из задания: какая доля исходных прочтений остаётся после фильтрации? Сколько прочтений в самом большом и самом маленьком образцах? Что это говорит о качестве данных?

Сводная статистика по всем 36 образцам

Этап	Сумма прочтений	% от входа	Что происходит на этом шаге
input	641 362	100,0	исходные прочтения после импорта
filtered	638 869	99,6	обрезка (trim/trunc) + фильтр по max-ee 3
denoised	622 542	97,1	исправление ошибок секвенирования
non-chimeric	608 362	94,9	удаление химерных последовательностей

До конца пайплайна доходит около **95 %** исходных прочтений — очень высокая сохранность. Крайние по размеру образцы:

Образец	Вход	Non-chimeric	Доля
Самый маленький — SRR17307380 (k0, повтор 2, день 360)	5 128	4 809	93,8 %
Самый большой — SRR17307475 (k0, повтор 3, день 90)	45 492	43 517	95,7 %

Фрагмент таблицы по отдельным образцам

sample-id	input	filtered	% passed filter	denoised	non-chimeric	% non-chimeric
SRR17307258	26 992	26 932	99,78	26 472	25 395	94,08
SRR17307262	5 996	5 926	98,83	5 754	5 731	95,58
SRR17307273	23 451	23 405	99,80	23 023	20 966	89,40
SRR17307316	10 833	10 723	98,98	10 193	10 189	94,06
SRR17307380	5 128	5 087	99,20	4 830	4 809	93,78
SRR17307409	29 485	29 434	99,83	28 819	28 088	95,26
SRR17307419	24 624	24 574	99,80	23 982	23 904	97,08

Показаны 7 из 36 образцов для иллюстрации разброса; полная таблица — в `soil_reads.dada2.stats.qzv`

Доля прошедших фильтр качества (столбец filtered) почти везде превышает 98–99 % — значит, параметр max-ee 3 почти ничего не отсеивает, то есть прочтения изначально чистые. Основные потери приходится на удаление химер (разница между denoised и non-chimeric): у большинства образцов это 0–3 %, но у отдельных, например SRR17307273, доходит почти до 9 % (23 023 → 20 966). Итоговая таблица ASV после DADA2 содержит **1 944 уникальных варианта ампликонов** на все 36 образцов.

Что это говорит о качестве данных. Во-первых, высокая доля прошедших каждый этап (95 % до конца) — признак хорошей библиотеки и разумно подобранных параметров обрезки: если бы качество было низким, фильтр по max-ee отсеивал бы заметно больше. Во-вторых, доля химер стабильно мала (в среднем 1–2 %, редко выше), что говорит об аккуратной постановке ПЦР без избыточного числа циклов. В-третьих, единственная реальная проблема — не качество, а **неравномерная глубина секвенирования**: разница между самым богатым и самым бедным образцом почти девятикратная (45 492 против 5 128). Это напрямую определяет следующий шаг анализа: все образцы придётся прореживать до глубины самого бедного (4 809 прочтений), иначе оценки разнообразия будут смещены в пользу глубже отсеквенированных образцов.

Задача 4. Почему достаточно классификатора, обученного на V4

Вопрос из задания: праймеры 515F/907R были подобраны для ампликона V4-V5 — почему хватает классификатора, обученного только на V4?

Пара праймеров 515F/907R действительно захватывает оба гипервариабельных участка, V4 и V5, и полный ампликон имеет длину около 400 п.н. Но в анализ идут не все 400 нуклеотидов, а только то, что остаётся от прочтения R1 после обработки:

- прочтение R1 — 250 нт, начинается сразу с праймера 515F;
- `--p-trim-left 25` убирает праймер и небольшой запас;
- `--p-trunc-len 200` обрезает некачественный хвост;
- итоговый фрагмент ASV — **175 п.н.**, считая от конца праймера 515F.

Участок V4 по стандартной нумерации гена 16S rRNA начинается сразу за позицией праймера 515F и простирается примерно до позиции праймера 806R, то есть занимает около 290 п.н. Наш фрагмент в 175 п.н. полностью укладывается внутрь этого интервала и не доходит до начала V5 (это уже за пределами R806). R2, который мог бы захватить V5 со стороны праймера 907R, в анализе не используется вовсе — именно поэтому V5 фактически не представлен в данных, несмотря на то что праймеры исходно рассчитаны на оба участка.

Наивный байесовский классификатор, который использует QIIME 2, сравнивает короткие подстроки (k-меры) запроса с k-мерами обучающих последовательностей из базы GreenGenes2. Если обучить его на полном V4-V5, значительная часть «знаний» модели будет приходиться на k-меры из V5 — участка, которого в наших последовательностях попросту нет, а значит бесполезной для классификации конкретно этих ASV. Классификатор, обученный ровно на V4 (2022.10.backbone.v4.nb.sklearn-1.4.2.qza), соответствует реальному составу данных лучше: все его k-меры релевантны фрагменту, который мы в действительности анализируем.

Задача 5. Таксономический состав почвенных сообществ

Вопрос из задания: посмотрите распределение классов (Level 3), отсортировав по level_and_time_point. Похожи ли образцы в первой точке? Как меняется состав со временем? Какие классы самые частые в первой и последней точках? На уровне рода (Level 6) — какой род самый частый в загрязнённых образцах и ожидаемо ли это?

Уровень класса (Level 3)




Рис. 3. Относительная представленность классов бактерий (Level 3), образцы упорядочены по level_and_time_point: сначала k0 (t1→t4), затем k5 (t1→t4), затем k25 (t1→t4)

Первая точка (3-и сутки). Образцы k0_t1, k5_t1 и k25_t1 визуально почти неразличимы — все девять образцов (три уровня × три реплики) показывают практически один и тот же набор долей:

Класс	k0_t1	k5_t1	k25_t1
Acidobacteriae	19,0 %	18,1 %	19,5 %
Alphaproteobacteria	16,7 %	16,1 %	17,0 %
Actinomycetia	10,5 %	10,8 %	11,2 %
Gammaproteobacteria	9,7 %	10,4 %	9,3 %
Thermoleophilia	7,4 %	7,4 %	8,7 %

Это ожидаемо: за трое суток почвенное сообщество просто не успевает перестроиться, какая бы доза керосина ни была внесена. Одновременно это служит проверкой самого эксперимента — исходная почва для всех вариантов была одна и та же.

Динамика во времени. Дальше траектории трёх вариантов расходятся, и нагляднее всего это видно по классу Gammaproteobacteria (куда входит основной деструктор, см. ниже) и по классу Acidobacteriae (фоновые олиготрофные почвенные бактерии, живущие на бедных ресурсах) — они меняются почти зеркально:

Gammaproteobacteria, %					Acidobacteriae, %				
Группа	t1	t2	t3	t4	Группа	t1	t2	t3	t4
k0	9,7	8,9	8,8	6,4	k0	19,0	37,2	45,3	47,9
k5	10,4	29,7	46,5	9,0	k5	18,1	28,5	20,5	46,1
k25	9,3	32,3	60,6	87,5	k25	19,5	21,8	5,9	1,2

Вырисовываются три разных сценария. В **контроле (k0)** доля Acidobacteriae постепенно растёт (19 % → 48 %) — это естественная сукцессия в закрытой ёмкости без притока новых бактерий и питательных веществ, никак не связанная с керосином, и её нужно держать в уме как фон для сравнения. При **сильном загрязнении (k25)** Gammaproteobacteria монотонно наращивают долю и к 360-му дню занимают почти 88 % сообщества, а исходные доминанты (Acidobacteriae)

почти полностью вытесняются (1,2 %) — сообщество за год не восстановилось, а ушло от исходного состояния ещё дальше. При **слабом загрязнении (k5)** до 180-го дня картина похожа на k25 (Gammaproteobacteria растут до 46 %), но к 360-му дню происходит разворот: доля Gammaproteobacteria падает обратно до 9 %, а Acidobacteriae возвращаются к 46 % — почти на уровень контроля.

Точка	k0 — самые частые классы	k5	k25
t1 (день 3)	Acidobacteriae 19,0 %, Alphaproteobacteria 16,7 %	Acidobacteriae 18,1 %, Alphaproteobacteria 16,1 %	Acidobacteriae 19,5 %, Alphaproteobacteria 17,0 %
t4 (день 360)	Acidobacteriae 47,9 %, Alphaproteobacteria 16,3 %	Acidobacteriae 46,1 %, Alphaproteobacteria 11,8 %	Gammaproteobacteria 87,5 % , Alphaproteobacteria 3,4 %

Уровень рода (Level 6)




Рис. 4. Относительная представленность родов (Level 6), тот же порядок образцов

Весь прирост Gammaproteobacteria в загрязнённых образцах обеспечивает практически один род — **Paraburkholderia** (семейство Burkholderiaceae):

<i>Paraburkholderia</i> , %	t1	t2	t3	t4
k0	не обнаружен	не обнаружен	не обнаружен	не обнаружен
k5	—	15,1	24,4	5,7
k25	—	26,7	50,7	83,6

Самый частый род в загрязнённых образцах — Paraburkholderia, и увидеть именно его при загрязнении керосином вполне ожидаемо. Этот род выделен из прежнего рода *Burkholderia* (семейство Burkholderiaceae), представители которого хорошо известны как деструкторы органических поллютантов: они способны использовать алифатические и ароматические углеводороды, то есть компоненты керосина, в качестве источника углерода и энергии. В незагрязнённой почве углерода мало, и преимущество получают олиготрофы вроде Acidobacteriae, умеющие выживать на скудном рационе. Как только вносится керосин, условия меняются на обратные: углерода становится много, но в форме, которую большинство почвенных бактерий перерабатывать не умеют — а те немногие, кто умеет, получают колоссальное конкурентное преимущество и вытесняют остальное сообщество. Косвенно это подтверждается и присутствием в данных k5 других известных деструкторов углеводородов (*Nevskia*, *Rhodanobacter*, *Mycobacterium*) — то есть на загрязнение реагирует не один вид, а целая функциональная группа бактерий.

Задача 6. Бета-разнообразие: сходство образцов по weighted UniFrac

Вопрос из задания: опишите результаты PCoA. Похожи ли образцы в первой точке? Как меняется их положение со временем? Есть ли признаки восстановления после слабого или сильного загрязнения?




Рис. 5. PCoA по матрице взвешенного UniFrac (Emperor), раскраска по level and time_point — каждый цвет соответствует своему сочетанию уровня загрязнения и временной точки

На графике ось 1 объясняет основную долю различий между образцами, ось 2 — заметно меньшую, ось 3 — совсем небольшую. Качественная картина полностью согласуется с таксономическим составом из задачи 5:

- **Первая точка (t1).** Образцы k0, k5 и k25 на 3-и сутки лежат плотной единой группой — разделения по дозе загрязнения ещё не видно, ровно как и на барплоте состава.
- **Контроль (k0).** Смещается заметно, но в основном вдоль второй оси — это эффект самой инкубации (рост доли Acidobacteriae), а не керосина.
- **Сильное загрязнение (k25).** Образцы последовательно и всё сильнее уходят от исходного положения по ходу времени (t1 → t2 → t3 → t4) и к 360-му дню оказываются дальше всего от контроля — признаков возврата нет.
- **Слабое загрязнение (k5).** До 180-х суток траектория похожа на k25 — образцы смещаются в ту же сторону. Но к 360-м суткам они возвращаются обратно, ближе к положению контрольных образцов того же времени — то есть сообщество по общей структуре восстанавливается.

Статистическую значимость этих различий подтверждает PERMANOVA (999 перестановок) по матрице weighted UniFrac:

Сравнение	pseudo-F	p-value	Вывод
k0 vs k25	13,97	0,001	сильно различаются
k0 vs k5	6,09	0,004	различаются
k5 vs k25	4,63	0,012	различаются
k0_t1 vs k5_t1	1,60	0,191	в первой точке различий нет
d3 vs d90	20,39	0,001	сильный эффект времени
d90 vs d180	2,05	0,142	незначимо
d180 vs d360	0,87	0,401	незначимо

Вывод по задаче 6. В первой временной точке сообщества неразличимы вне зависимости от будущей дозы загрязнения, что подтверждено и статистически ($p = 0,191$ для k0 vs k5 на t1). Разделение по дозе керосина нарастает со временем и наиболее выражено к 360-м суткам. Признаки восстановления есть только у слабого загрязнения: образцы k5 к концу эксперимента возвращаются близко к траектории контроля. При сильном загрязнении (k25) возврата не

происходит — сообщество продолжает удаляться от исходного состояния на протяжении всего года наблюдения.

Задача 7. Альфа-разнообразие: динамика индекса Шеннона

Вопрос из задания: опишите, как меняется разнообразие бактериального сообщества со временем при разном уровне загрязнения.




Рис. 6. Индекс Шеннона по группам level_and_time_point (глубина прореживания — 4 809 прочтений, по самому бедному образцу)

Группа	t1 (день 3)	t2 (день 90)	t3 (день 180)	t4 (день 360)
k0 (контроль)	8,99	8,91	8,65	8,27
k5 (5 г/кг)	9,07	7,80	6,62	6,77
k25 (25 г/кг)	8,94	7,61	5,91	2,93

Старт у всех трёх вариантов практически одинаковый (8,94–9,07 на 3-и сутки) — за трое суток керосин ещё не успевает повлиять на разнообразие, что согласуется с результатами задач 5 и 6. Дальше кривые расходятся, и чем выше доза, тем быстрее и глубже падает разнообразие.

В **контроле** снижение небольшое и плавное (8,99 → 8,27 за год) — это естественная сукцессия в закрытой системе: питательные вещества постепенно истощаются, несколько групп (в первую очередь *Acidobacteriae*) получают конкурентное преимущество, равномерность распределения долей падает. При **слабом загрязнении** разнообразие падает быстрее уже к 90-м суткам (7,80 против 8,91 у контроля) и продолжает снижаться до 180-х суток (6,62), но затем стабилизируется — к 360-м суткам значение даже немного растёт (6,77). Эта остановка падения согласуется с тем, что по составу (задача 5) и по положению на PCoA (задача 6) сообщество k5 к этому моменту возвращается к состоянию, близкому к контролю. Разрыв с контролем при этом сохраняется (6,77 против 8,27), то есть правильнее говорить не о полном восстановлении, а о том, что деградация сообщества прекратилась и начался частичный откат назад.

При **сильном загрязнении** падение не останавливается на всём протяжении эксперимента и к 360-м суткам индекс обваливается до 2,93 — это вдвое ниже контроля и экстремально низкое значение для почвенного сообщества. Это прямое следствие доминирования одного рода: когда *Paraburkholderia* занимает 83,6 % прочтений (задача 5), индекс Шеннона физически не может оставаться высоким, какой бы ни была глубина прореживания.

Вывод по задаче 7. Керосин снижает альфа-разнообразие дозозависимо. При слабом загрязнении падение останавливается к середине эксперимента, и далее сообщество, по-видимому, движется к восстановлению, хотя за год полностью его не достигает. При сильном загрязнении падение продолжается непрерывно весь год без каких-либо признаков разворота.

Общий вывод

1. Качество исходных данных высокое: после всех стадий DADA2 сохраняется около 95 % прочтений, доля химер минимальна (в среднем 1-2 %). Единственное существенное

ограничение данных — почти девятикратный разброс глубины секвенирования между образцами, учтённый прореживанием до 4 809 прочтений.

2. На 3-и сутки после внесения керосина никаких различий между контролем и загрязнёнными образцами нет ни по таксономическому составу, ни по бета-, ни по альфа-разнообразию — трёх суток почвенному сообществу недостаточно, чтобы отреагировать.
3. Дальнейшая динамика принципиально разная в зависимости от дозы. При **5 г/кг** сообщество проходит через временное возмущение (рост деструкторов-углеводородокислителей, падение разнообразия), но к концу года возвращается к состоянию, близкому к контролю, — вероятно, после того как керосин в основном разложен. При **25 г/кг** возмущение не затухает: род *Paraburkholderia* занимает почти всё сообщество (83,6 % к 360-м суткам), разнообразие падает почти до нуля ($H \approx 2,93$), и никаких признаков восстановления за год не возникает.
4. Главный «ответчик» на загрязнение керосином на всех уровнях анализа — семейство Burkholderiaceae, в первую очередь род *Paraburkholderia*, что согласуется с известной способностью этой группы разлагать алифатические и ароматические углеводороды.
5. Практический вывод: существует порог устойчивости почвы к загрязнению керосином, лежащий где-то между 5 и 25 г/кг — ниже него экосистема справляется сама в течение года, выше него однолетнего периода недостаточно даже для признаков восстановления.